ACADEMIA DE STUDII ECONOMICE BUCUREȘTI
FACULTATEA DE CIBERNETICĂ, STATISTICĂ ȘI INFORMATICĂ ECONOMICĂ

Proiect Inteligență Computațională în Economie

Coordonator ştiinţific:
Domențeanu Adrian

Student: Anin Andreea-Cristina
Anul III

1. Descrierea datelor și statistici descriptive

Descrierea datelor

Setul de date a fost preluat de pe platforma Kaggle (https://www.kaggle.com/) și conține informații despre performanțele comerciale ale unor cărți, fiind potrivit pentru analize de tip economic și de business intelligence.

Variabilele pe care le voi folosi în analiză sunt:

- Date despre vânzări și performanță financiară
  - Publisher_revenue: venitul net încasat de editură după deducerea comisioanelor sau costurilor asociate
  - Sale price: prețul de vânzare al cărții, reflectând poziționarea pe piață, strategia de preț
  - Units_sold: numărul de exemplare vândute, un indicator-cheie al cererii de piață și al succesului comercial

- Indicatori de piață și competitivitate
  - Sales_rank: locul ocupat în clasamentul vânzărilor (probabil în cadrul unei platforme ca Amazon);
  - Book_average_rating și Book_ratings_count: indicatori ai percepției publice și satisfacției clienților, care pot influența cererea și reputația autorului/editurii

- Categorii și segmente de piață
  - Genre: ajută la segmentarea pieței pe interese tematice (fiction sau nonfiction)
  - Publisher: permite analiza performanței economice în funcție de companiile care publică cărțile
  - Author_Rating: clasificare a autorilor pe baza succesului și reputației (Novice, Intermediate, Famous, Excellent); utilă în analize de brand și loialitate.

Statistici descriptive

	vars	n	mean	sd	median	trimmed	mad	min	max	range	skew
Book_average_rating	1	500	3.99	0.25	4.00	4.00	0.24	3.21	4.77	1.56	-0.32
Book_ratings_count	2	500	102979.63	31304.66	98527.50	100662.12	31477.08	35283.00	199872.00	164589.00	0.62
Publisher_revenue	3	500	1563.36	3081.88	674.77	869.37	588.84	64.15	28677.00	28612.85	4.86
Sale_price	4	500	5.65	3.91	5.06	5.34	4.35	0.99	33.86	32.87	1.35
Sales_rank	5	500	486.86	307.64	466.50	468.27	349.15	1.00	1226.00	1225.00	0.43
Units_sold	6	500	10968.51	16671.45	3982.50	7569.25	4862.93	107.00	61560.00	61453.00	1.50

	kurtosis	se
Book_average_rating	0.45	0.01
Book_ratings_count	-0.04	1399.99
Publisher_revenue	28.92	137.83
Sale_price	5.69	0.17
Sales_rank	-0.52	13.76
Units_sold	0.65	745.57

Figura 1. Statistici descriptive

- Book_average_rating
  - Media este 3.99 (aproape 4 stele), iar mediana este are valoarea 4, așadar distribuția este aproape simetrică
  - Skew = -0.32 arată o ușoară asimetrie spre stânga (majoritatea cărților au scoruri mai mari)
  - Kurtosis = 0.45 indică o distribuție relativ plată, fără cozi extreme

- Book_ratings_count
  - Media = 102979, Abaterea standard = 31304 → distribuție foarte dispersată
  - Skew = 0.62 → asimetrie spre dreapta (există cărți cu număr mare de review-uri)
  - Minim = 35283, Maxim = 199872 → gamă largă a vizibilității publice
  - Kurtosis aprope de 0 → distribuție aproape normală, dar cu variații mari

- Publisher_revenue
  - Deviația standard (sd = 3081.88) e de aproape două ori mai mare decât media, astfel că variabilitatea este foarte mare
  - Skew = 4.86 arată că majoritatea valorilor sunt mici, dar există câteva valori extrem de mari (outlieri) care trag media în sus
  - Kurtosis = 28.92 indică că datele sunt concentrate puternic în jurul medianei (674.77), dar cu câteva valori extreme foarte îndepărtate (28677)

- Sale_price
  - Media = 5.65, Mediana = 5.06 → distribuție asimetrică spre dreapta (skew = 1.35)
  - Prețul minim e 0.99, maxim 33.86 → variație mare, dar concentrată spre intervale mici.
  - Kurtosis = 5.69 → prețurile au o distribuție cu cozi mai groase (câteva prețuri ieșite din comun)

- Sales_rank
  - Media = 486, Mediana = 466 → distribuție relativ echilibrată
  - Skew = 0.43 → ușor asimetric spre dreapta

- Minim = 1 → există cel puțin o carte care se află pe locul 1 în topul vânzărilor

- Units_sold
  - Media = 10968, Mediana = 3982, skew = 1.5 → distribuție puternic asimetrică spre dreapta
  - Kurtosis = 0.65 → ușor bombată, dar nu extremă (câteva cărți au avut vânzări foarte mari, dar cele mai multe au avut vânzări modeste)

Am realizat și boxplot-uri pentru aceste variabile pentru a identifica outlierii.

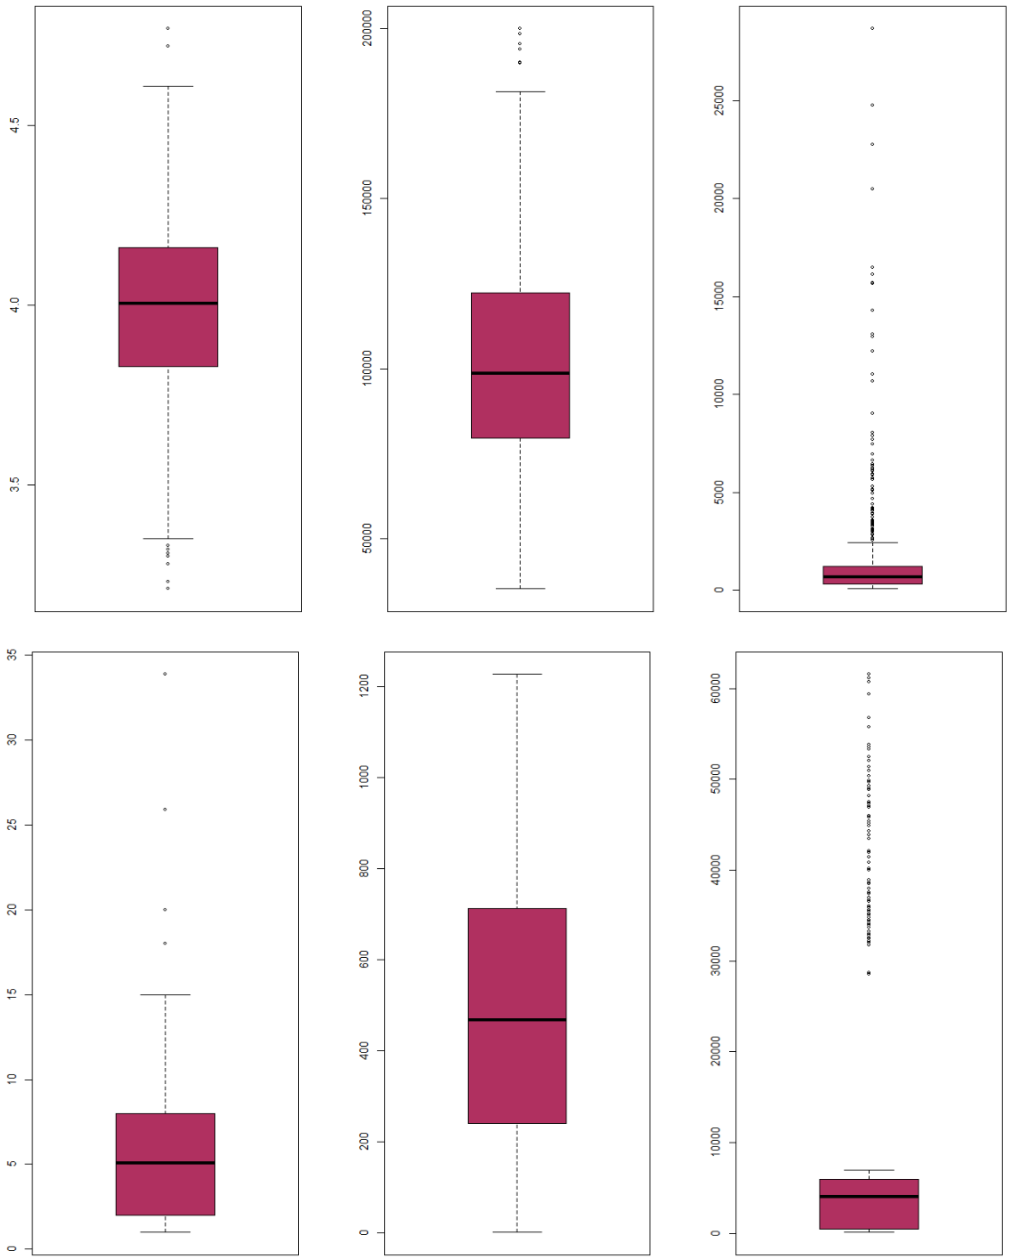

Figura 2. Boxplot-uri

Se poate observa că variabilele Publisher_revenue și Units_sold au outlierii destul de mulți, așa că am descis să îi elimin pentru a nu afecta mai departe analiza.

2. Utilizarea metodei intitulată „Clusterizare fuzzy”

Am realizat clusterizarea fuzzy cu variabilele Book_average_rating, Book_ratings_count, Sales_rank și am folosit funcția „cmeans” din librăria „e1071”. Pentru asta, am ales 3 clustere, 100 de iterații pentru algoritm și m=2 care reprezintă gradul de fuzzificare, adică controlează cât de mult pot aparține punctele de mai multe clustere.

```
Fuzzy c-means clustering with 3 clusters

Cluster centers:
  Book_average_rating Book_ratings_count Sales_rank
1            3.934519           69788.24   807.6583
2            4.043226          140498.77   206.5162
3            3.999314          102275.26   421.0637
```

Figura 3. Centroizii clusterelor

În cazul algoritmului fuzzy c-means, centroizii sunt calculați ca mediile clusterelor. Clusterul 2 are Book_average_rating maxim (4.043), urmat de clusterul 3 (3.999) și clusterul 1 (3.934). Book_ratings_count maxim este 140498.77, tot pentru clusterul 2, ceea ce indică că acest cluster conține cărțile cele mai preferate de cititori.

```
Memberships:
                 1            2            3
  [1,] 4.309343e-02 8.529438e-01 1.039627e-01
  [2,] 4.205041e-05 9.998126e-01 1.453906e-04
  [3,] 5.519589e-02 1.521219e-01 7.926823e-01
  [4,] 7.890111e-02 7.549351e-01 1.661638e-01
  [5,] 1.612432e-02 9.391976e-01 4.467811e-02
  [6,] 1.211599e-01 6.563548e-01 2.224853e-01
  [7,] 2.286582e-02 9.163090e-01 6.082515e-02
  [8,] 8.691005e-03 9.658377e-01 2.547130e-02
  [9,] 1.908829e-02 8.957736e-01 8.513808e-02
 [10,] 3.769742e-03 9.845856e-01 1.164468e-02
```

Figura 4. Gradele de apartenență ale cărților la cele 4 clustere

Prima carte aparține clusterului 1 cu gradul $4.309*10^{-2}$, clusterului 2 cu gradul $8.529*10^{-1}$, etc. Dacă luăm pe fiecare linie gradul maxim de apartenență, putem să decidem cărui cluster aparține cartea respectivă. De exemplu, maximul de pe prima linie este 0.8529, deci prima carte aparține clusterului 2, a doua tot clusterului 2, a treia clusterului 3 și așa mai departe.

	Book	Cluster
1	It's Kind of a Funny Story	2
2	The Language of Flowers	2
3	Men Are from Mars, Women Are from Venus Book of Days: ...	3
4	Tuck Everlasting	2
5	Christine	2
6	Scarlet	2
7	Rich Dad , Poor Dad	2
8	The Magicians	2
9	Everything Is Illuminated	2
10	Girl, Interrupted	2
11	Love You Forever	2
12	The Drawing of the Three	2
13	This Lullaby	2
14	The Hound of the Baskervilles	2
15	Thinking, Fast and Slow	2

```
Closest hard clustering:
  [1] 2 2 3 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 3 2 2 2 2 2 2 2 3 2 2 3 2 2 2 2 3 2 2 2 2 3 2 2 2 2 3 3 2 1 3
 [55] 3 2 2 2 2 2 2 2 3 3 3 2 2 3 3 3 3 2 2 3 3 3 3 2 2 3 1 3 2 3 3 2 3 3 3 3 3 3 2 2 3 3 3 3 3 3 3 3 1 3 3 2 3
[109] 2 2 3 3 3 1 3 3 3 3 1 3 3 3 3 2 2 3 2 3 3 3 3 3 1 1 3 3 2 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 2 1 3 1
[163] 2 3 3 3 3 3 3 3 3 3 3 2 1 3 3 3 3 3 3 3 3 1 1 3 3 1 3 3 1 3 3 1 3 3 3 3 3 3 1 3 3 3 3 3 3 1 1 1 3 1 3 3 1
[217] 3 1 3 1 2 3 3 3 2 1 1 3 3 3 1 1 1 3 3 1 1 1 3 3 1 3 1 1 3 3 3 1 3 1 3 1 1 1 1 3 1 3 1 1 3 3 1 1 3 3 1 1 3 1
[271] 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 3 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1
```

Figura 5. Apartența cărților la cele 3 clustere

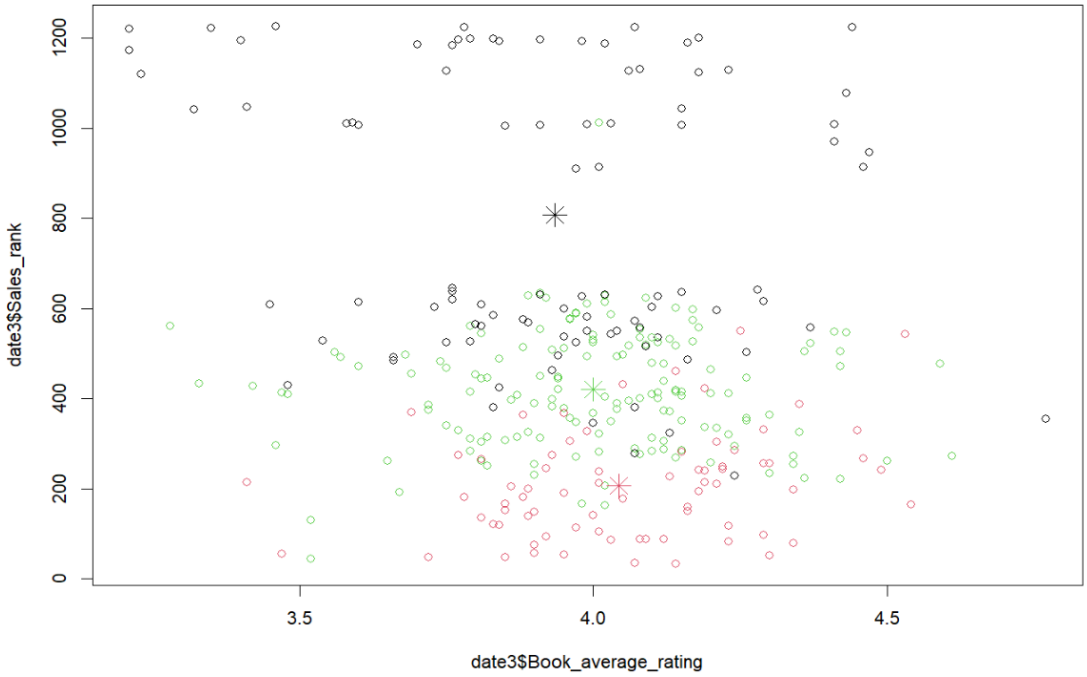

Figura 6. Reprezentarea grafică a centroiziilor

Cercurile colorate reprezintă observațiile care aparțin celor 3 clustere (sunt colorate diferit pentru fiecare cluster), iar steluțele sunt centroizii.

Am făcut și graficul Silhouette pentru a evalua calitatea clusterizării.

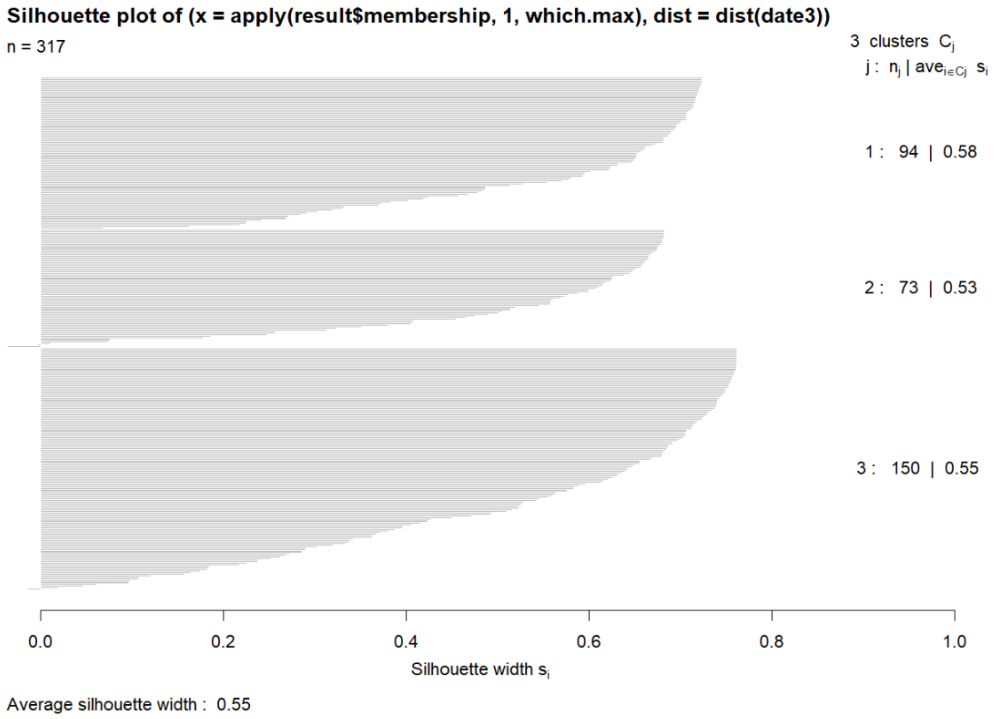

Figura 7. Graficul Silhouette

Clusterizarea fuzzy cu 3 grupuri este stabilă și bine definită, cu o calitate globală bună (scor mediu 0.55), ceea ce înseamnă că majoritatea punctelor sunt bine încadrate în clusterul lor. Nu sunt clustere cu scoruri foarte mici (sub 0.25), deci nu există dovezi clare că unele observații au fost atribuite greșit. Cel mai definit cluster este clusterul 1, cu silhouette width de 0.58, în timp ce clusterul 2 are cea mai mică valoare pentru silhouette width (0.53), dar chiar și acesta are o calitate acceptabilă.

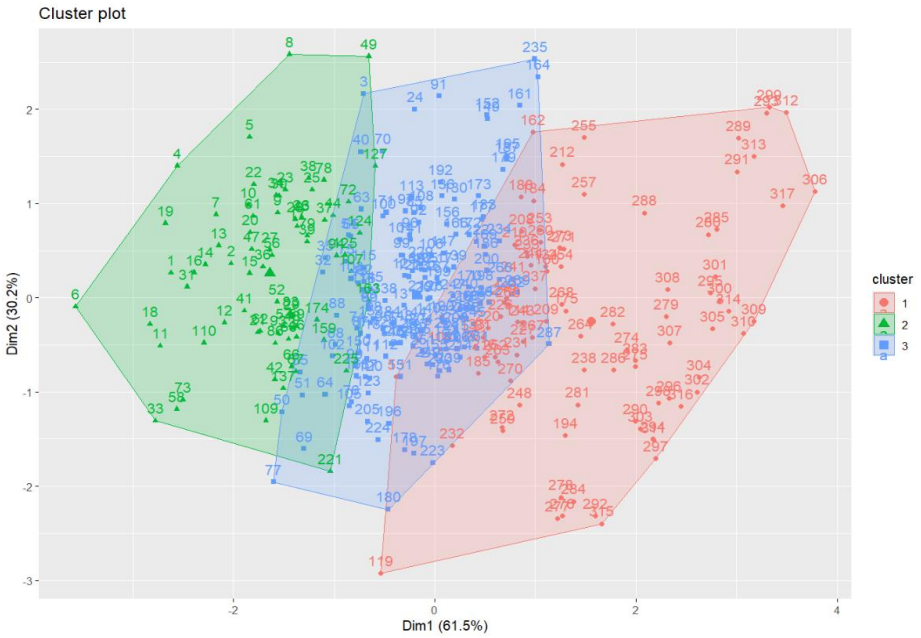

Figura 8. Reprezentarea grafică a clusterelor

Clusterul 2 (verde) conține cărți cu ratinguri medii mai mari, dar mai puține recenzii și rank mai slab (adică vânzări mai mici). Acest cluster este reprezentat de cărți apreciate de cititori, dar mai puțin populare. Clusterul 3 (albastru) evidențiează cărțile cu caracteristici mixte/moderate - rating mediu, număr de recenzii intermediar, rank mediu. Acesta este un cluster de tranziție, conținând titluri cu performanță echilibrată. Clusterul 1 (roșu) conține cărți cu multe recenzii, rank bun (valori mici), dar ratinguri mai scăzute. Acestea par a fi cărți comerciale cu vânzări mari, dar poate nu la fel de bine apreciate de cititori.

3. Exemplificarea algoritmilor de regresie logistică binomială și multinomială

Regresie logistică binomială

Pentru regresia logistică binomială am creat o nouă variabilă numită High_Sales, pentru a putea clasifica cărțile în două categorii pe baza vânzărilor.

Variabila are următoarele valori:

- 1, dacă Units_sold > mediana (adică vânzare mare);
- 0, altfel (vânzare mică).

Pe urmă, am transformat variabila dependentă (High_Sales) în variabilă de tip factor.

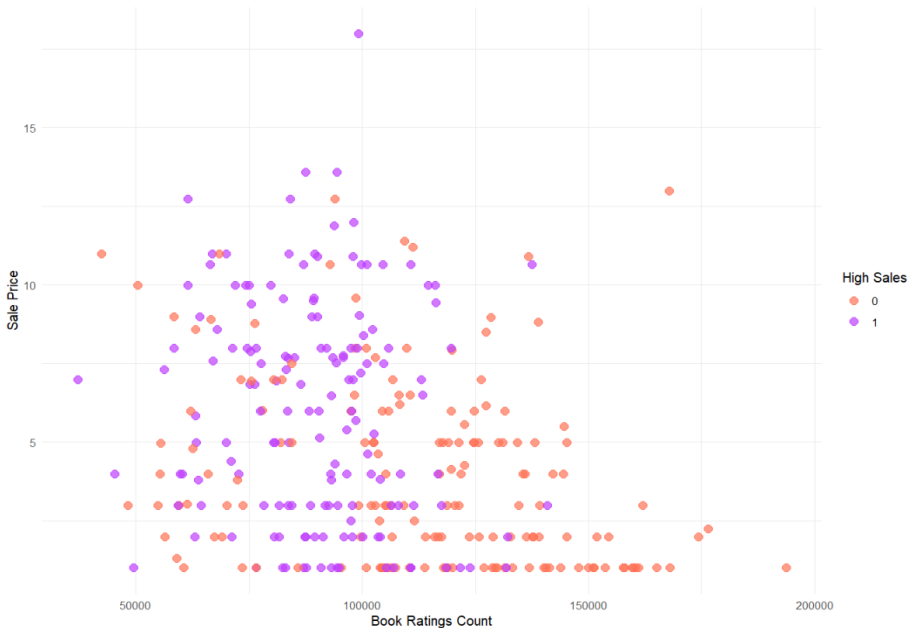

Figura 9. Grafic între Book_ratings_count și Sale_price

Cele mai multe cărți au sub 150.000 de evaluări și un preț sub 10. Există o mare densitate de puncte în zona inferioară a graficului, acest lucru indicând că cele mai multe cărți sunt ieftine și au un număr moderat de recenzii.

Cărțile cu vânzări mari (puncte mov) nu se concentrează la prețuri ridicate. De fapt, multe dintre ele se găsesc în zona cu prețuri mici (sub 5). De aici se deduce că prețurile mici sunt asociate mai frecvent cu vânzări mari, fiind o observație tipică în comerț.

Cărțile cu multe evaluări (peste 100.000) tind să aibă mai frecvent eticheta High Sales = 1, dar nu exclusiv, exitând și multe cărți cu multe evaluări dar vânzări mici (punctele portocalii).

```
Call:
glm(formula = High_Sales.f ~ Book_ratings_count + Sale_price,
    family = binomial, data = setantrenare)

Coefficients:
                     Estimate Std. Error z value Pr(>|z|)
(Intercept)         2.879e+00  7.457e-01   3.861 0.000113 ***
Book_ratings_count -3.543e-05  6.546e-06  -5.412 6.24e-08 ***
Sale_price          1.247e-01  4.545e-02   2.743 0.006082 **
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 329.67  on 237  degrees of freedom
Residual deviance: 270.34  on 235  degrees of freedom
AIC: 276.34

Number of Fisher Scoring iterations: 4
```

Figura 10. Output regresie logistică binomială

Ecuația regresiei logistice binomiale:

logit(p)= 2.879 – 3.543*10^{-5}*Book_ratings_count + 0.1247*Sale_price,

unde p reprezintă probabilitatea ca vânzarea să fie mare, adică peste mediană (High_Sales = 1), iar 1-p este probabilitatea ca vânzarea sa fie mică (High_Sales = 0).

Variabilele independente au p-value mai mic decât 0.05, deci predictorii sunt semnificativi statistic. Devianța reziduală este 270.34, mai mică decât cea a modelului nul (329.67), astfel că modelul actual, adică cel în care s-au adăugat variabilele independente, este mai bun decât modelul nul. AIC are o valoare destul de mică.

Am aplicat funcția exponențială asupra coeficienților modelului de regresie logistică pentru a vedea impactul variabilelor analizate asupra șanselor ca vânzarea unei cărți să fie mare.

```
(Intercept) Book_ratings_count         Sale_price
 17.7989951          0.9999646          1.1328062
```

Figura 11. Rezultate funcție exponențială

Pentru fiecare recenzie în plus, șansele ca o carte să fie în categoria High_Sales scad cu 0.004% (0.99996 - 1 = - 0.00004*100). Pentru fiecare unitate monetară în plus la prețul cărții, șansele ca o carte să aibă vânzare mare cresc cu aproximativ 13% (1.1328062 - 1 = 0.1328*100).

```
         1          2          3          4          5          6          7          8          9         10
0.08686006 0.02059283 0.11759914 0.14900262 0.14721172 0.36088594 0.19132196 0.17154448 0.26686003 0.23515699
        11         12         13         14         15         16         17         18         19         20
0.11886289 0.17080648 0.25962409 0.15205356 0.23242814 0.34362088 0.75873055 0.18030424 0.37385006 0.38490175
        21         22         23         24         25         26         27         28         29         30
0.28073064 0.48512569 0.46869598 0.27225894 0.75716646 0.48128469 0.19039813 0.78679638 0.32847122 0.46691581
        31         32         33         34         35         36         37         38         39         40
0.71459161 0.32431191 0.80450464 0.39991154 0.33323719 0.48892418 0.41028434 0.85895878 0.21251020 0.62236348
        41         42         43         44         45         46         47         48         49         50
0.28679588 0.43489076 0.53217495 0.49313128 0.50675371 0.56962464 0.52802386 0.32477011 0.71141634 0.70523692
        51         52         53         54         55         56         57         58         59         60
0.48949374 0.55785449 0.73531537 0.61840949 0.23148773 0.41696931 0.81700819 0.69143460 0.79822338 0.65787716
        61         62         63         64         65         66         67         68         69         70
0.52129839 0.56989195 0.66134387 0.69040452 0.44094734 0.42644816 0.66092049 0.81256020 0.84739858 0.66367803
        71         72         73         74         75         76         77         78         79
0.59808332 0.49008839 0.77856987 0.79671509 0.87536113 0.77629669 0.77923388 0.72126616 0.74475064
```

Figura 12. Probabilități folosind funcția predict

Probabilitatea ca prima carte să aibă vânzare mare este de 0.08, probabilitatea pentru a doua este 0.02 și așa mai departe.

În continuare, am definit un vector de valori pentru „0” (vânzare mică) corespunzător numărului de observații din setul de antrenare. Ulterior, elementul 0 este convertit în „1” atunci când probabilitatea previzionată ca o carte să aibă vânzări mari este mai mare decât 0.5.

```
pred  0  1
   0 70 60
   1 53 55
```

Figura 13. Matricea de confuzie pentru pred

Setul de antrenare conține 60 + 55 = 115 cărți care au avut vânzări mari (High_Sales = 1) și 70 + 53 = 123 cărți care nu au avut vânzări mari (High_Sales = 0).

Din cele 115 cărți cu vânzări mari, 55 au fost clasificate corect ca fiind High_Sales = 1, iar 60 au fost clasificate greșit ca având vânzări mici. Din cele 123 cărți cu vânzări mici, 70 au fost clasificate corect ca High_Sales = 0 și 53 au fost clasificate eronat ca având vânzări mari.

Acuratețea modelului: (70 + 55) / (70 + 60 + 53 + 55) = 0.52. Așadar 52% din elementele setului de antrenare au fost corect previzionate.

Mai departe, am introdus două cărți pentru a previziona dacă acestea au avut vânzări mari sau nu.

```
> predictie[1]<=0.5 #Prima carte are vanzare mica
    1
FALSE
> predictie[2]<=0.5 #A doua carte are vanzare mica
    2
FALSE
```

```
        1         2
0.9775080 0.9515817
```

Figura 14. Predicțiile pentru cele două cărți

```
pred1  0  1
    0 30 13
    1 11 25
```

Figura 15. Matricea de confuzie pentru pred1

În setul de testare sunt 13 + 25 = 38 cărți care au vânzări mari și 30 + 11 = 41 cărți cu vânzări mici. Din cele 38 cărți cu vânzări mari, 25 au fost clasificate corect, în timp ce 13 au fost clasificate greșit. Din cele 41 cărți cu vânzări mici, 30 au fost identificate corect, iar 11 au fost incorect etichetate. Acuratețea este de aproximativ 70% pentru setul de testare.

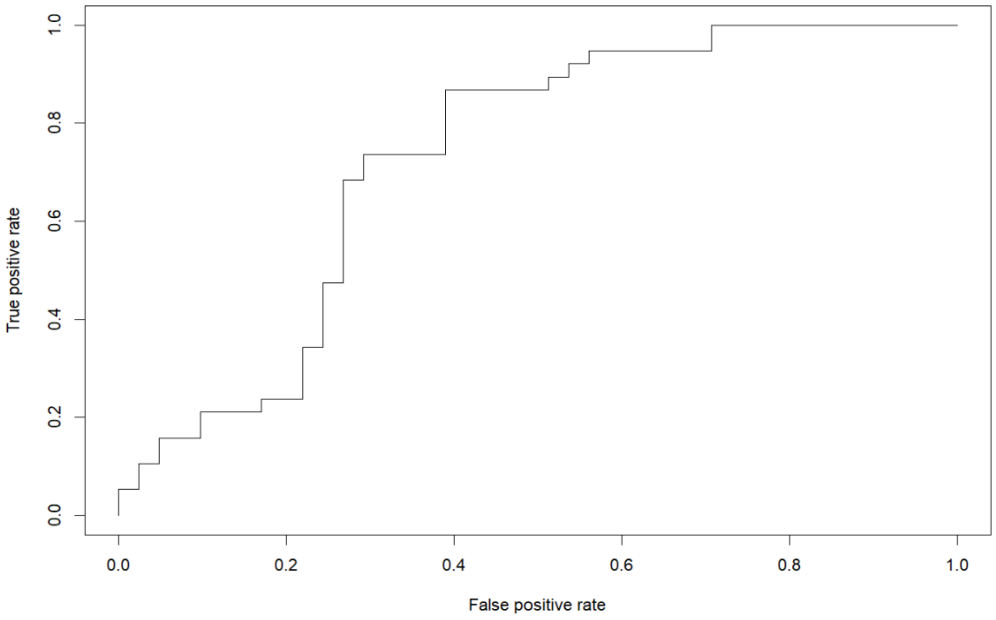

Figura 16. Grafic curba ROC

Din grafic se poate observa că, curba ROC se aproapie de colțul din stânga sus. Valoarea lui auc este de 0.7284981, adică clasificare este moderată, existând 73% șanse ca modelul să poate distinge între clasa pozitivă (vânzări mari) și clasa negativă (vânzări mici).

Regresie logistică multinomială

Pentru regresia logistică multinomială, am ales să transform variabila dependentă „Author_Rating" în variabila factor, numită „Author_RatingF". Variabila „Author_Rating" ia patru valori posibile: „Novice", „Intermediate", „Famous", „Excellent" și am stabilit un nivel de referință cu valoarea „Excellent".

```
Call:
multinom(formula = out ~ Units_sold + Sales_rank + Sale_price,
    data = date2, trace = FALSE)

Coefficients:
             (Intercept)    Units_sold    Sales_rank  Sale_price
Famous        -0.5218479 -0.0002228450  0.0001466325 -0.06829961
Intermediate   2.4685757 -0.0002782656 -0.0014879199 -0.04457975
Novice        -2.6965899 -0.0001727541  0.0015984121  0.08701221

Std. Errors:
             (Intercept)   Units_sold   Sales_rank Sale_price
Famous       0.003710734 1.069247e-04 0.0006186676 0.07025681
Intermediate 0.001657372 5.984136e-05 0.0004103959 0.03755775
Novice       0.002428106 1.198949e-04 0.0005867716 0.07089966

Residual Deviance: 580.7114
AIC: 604.7114
```

Figura 17. Output regresie logistică multinomială

Pentru clasa Famous

Ecuație: Y_1 = ln[P(Famous)/P(Excellent)] = - 0.522 - 0.0002*Units_sold + 0.0001*Sales_rank - 0.068*Sale_price

Intercept este - 0.522 și reprezintă valoarea de bază a log-odds pentru clasa Famous, când toți predictorii sunt 0. O creștere cu o unitate a numărului de unități vândute duce la scăderea logaritmului log-odds cu 0.0002, adică mai multe unități vândute scad ușor șansa autorului de a fi Famous. Valoarea lui Sales_rank (0.0001) arată că rang-ul cărții are un ușor efect pozitiv. Cărțile mai scumpe sunt mai puțin probabil să aibă un autor considerat Famous.

Le fel se face și pentru celelalte clase.

	(Intercept)	Units_sold	Sales_rank	Sale_price
Famous	0.59342295	0.9997772	1.0001466	0.9339806
Intermediate	11.80562009	0.9997218	0.9985132	0.9563993
Novice	0.06743508	0.9998273	1.0015997	1.0909100

Figura 18. Impactul variabilelor analizate

Pentru clasa Famous

O creștere cu o unitate a numărului de unități vândute scade șansele ca autorul să fie în categoria Famous cu aproximativ 0.02% (0.9998 - 1 = - 0.0002). O creștere cu o unitate în rangul vânzărilor crește șansele ca autorul să fie Famous cu 0.01%. Șansele ca un autor să fie clasificat ca Famous sunt cu 6.6% mai mici pentru fiecare unitate în plus la prețul de vânzare (Sale_price).

Le fel se face și pentru celelalte clase.

	Excellent	Famous	Intermediate	Novice
1	0.1344898	0.04631480	0.8108067	0.008388717
2	0.1274990	0.06454131	0.7919527	0.016006917
3	0.4984291	0.04414363	0.4043515	0.053075702

Figura 19. Probabilitățile folosind funcția predict pentru autorii cărților 3,100,150

Probabilitatea ca al treilea autor să fie în clasa Excellent este 0.134, în timp ce probabilitatea de a fi Famous este 0.046. Probabilitatea să fie Intermediate este de 0.811, în timp ce probabilitatea de a fi Novice este 0.008.

```
              Excellent Famous Intermediate Novice
  Excellent          28      0           64      0
  Famous              6      0           15      0
  Intermediate       20      0          167      0
  Novice              7      0           10      0
> #Acuratetea
> mean(date2$Author_Rating == predict(model2))
[1] 0.615142
```

Figura 20. Matricea de confuzie și acuratețea modelului

Valorile corecte sunt: 28 (Excellent), 0 (Famous), 167 (Intermediate), 0 (Novice), în total fiind 195. Clasele Famous și Novice nu sunt niciodată prezise, ceea ce înseamnă că modelul le ignoră complet. Acest lucru este posibil să se întâmple din cauza faptului că există un dezechilibru în date (exemple multe pentru Intermediate, puține pentru restul). Acuratețea modelului este de aproximativ 62%.

4. Folosirea arborilor de regresie și clasificare + Curățarea arborelui

Arbori de clasificare

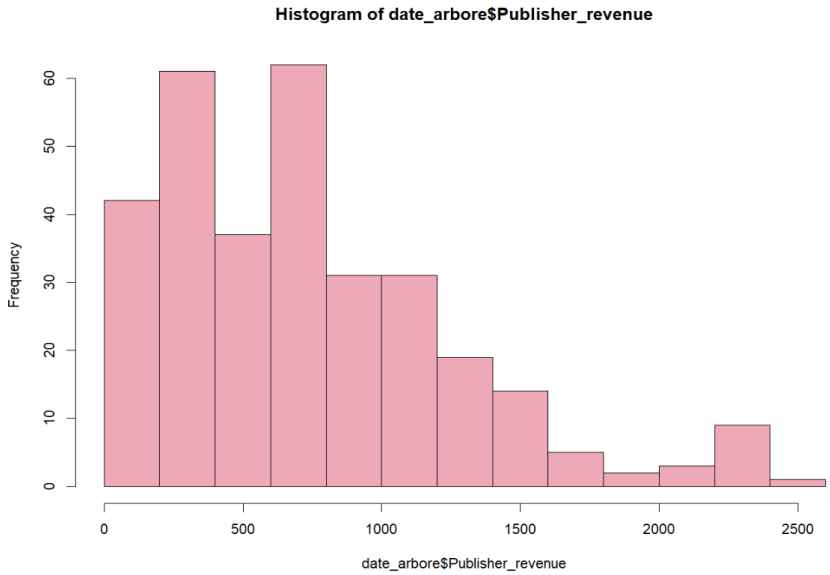

Figura 21. Histogramă pentru variabila Publisher_revenue

Din histograma de mai sus, se obervă că variabila Publisher_revenue are o ditribuție asimetrică spre dreapta, majoritatea editurilor au venituri între 0 și 1000, cu un vârf între 500 și 750. Există un număr mic de edituri cu venituri foarte mari (peste 2000), sugerând prezența unor valori extreme (outliers). Coada lungă spre dreapta arată faptul că există un număr mic de edituri de top care domină financiar piața, având veniturile încasate semnificativ mai mari decât restul.

Pentru această analiză, am transformat variabila numerică „Publisher_revenue” în variabila binară „High_Revenue” cu valorile „Yes” dacă „Publisher_revenue” > mediana (venit mare) și „No” (venit mic) în caz contrar.

```
n= 158

node), split, n, loss, yval, (yprob)
      * denotes terminal node

 1) root 158 74 Yes (0.4683544 0.5316456)
   2) Sale_price< 4.685 86 21 No (0.7558140 0.2441860)
     4) Author_Rating=Excellent,Famous,Novice 26  0 No (1.0000000 0.0000000) *
     5) Author_Rating=Intermediate 60 21 No (0.6500000 0.3500000)
      10) Sale_price< 1.49 25  5 No (0.8000000 0.2000000) *
      11) Sale_price>=1.49 35 16 No (0.5428571 0.4571429)
        22) Book_average_rating< 3.805 9  1 No (0.8888889 0.1111111) *
        23) Book_average_rating>=3.805 26 11 Yes (0.4230769 0.5769231)
          46) Book_average_rating>=3.925 19  9 No (0.5263158 0.4736842) *
          47) Book_average_rating< 3.925 7  1 Yes (0.1428571 0.8571429) *
   3) Sale_price>=4.685 72  9 Yes (0.1250000 0.8750000) *
```

Figura 22. Output arbore

- Nodul 1 (Rădăcina arborelui)
  - sunt 158 observații (cărți), dintre care 74 cazuri sunt etichetate greșit (predicție Yes, dar în realitate sunt No)
  - frecvențele pentru clase: 46.83% No și 53.16% Yes

  Arborele începe prin a împărți datele după Sale_price < 4.685

- Nodul 2: Sale_price < 4.685
  - 86 observații, din care 75.58% sunt No, deci predicția e No
  - Subramura 1: Author_Rating = Excellent, Famous, Novice (Nodul 4), unde sunt 26 observații și 100% No, deci e nod terminal, iar predicția e sigură
  - Subramura 2: Author_Rating = Intermediate (Nodul 5) - 65% No, 35% Yes, predicție No

  Mai departe se împarte din nou după Sale_price

  - Sale_price < 1.49 (Nodul 10): din cele 25, 5 sunt etichetate greșit (modelul prezice No, dar în 5 cazuri era Yes), nod terminal, predicție No
  - Sale_price >= 1.49 (Nodul 11): 54.29% No, 45.71% Yes, predicție No (aproape echilibrat)

  Pe urmă, arborele împarte după Book_average_rating

  - Book_average_rating < 3.805 (Nodul 22): 88.89% No, nod terminal
  - Book_average_rating >= 3.805 (Nodul 23): 57.69% Yes, predicție: Yes

  Mai departe, se mai împarte după Book_average_rating

- Nod 46 (>= 3.925): 19 observații, dintre care 52.63% No, deci este predicție No (nod terminal)
- Nod 47 (< 3.925): 7 observații, dintre care 85.71% Yes, deci este predicție Yes (nod terminal)

- Nodul 3 (Sale_price >= 4.685), unde sunt 87.5%, astfel că predicția este Yes (nod terminal, predicție foarte sigură)

Am realizat și graficul acestui arbore pentru o vizualizare mai bună.

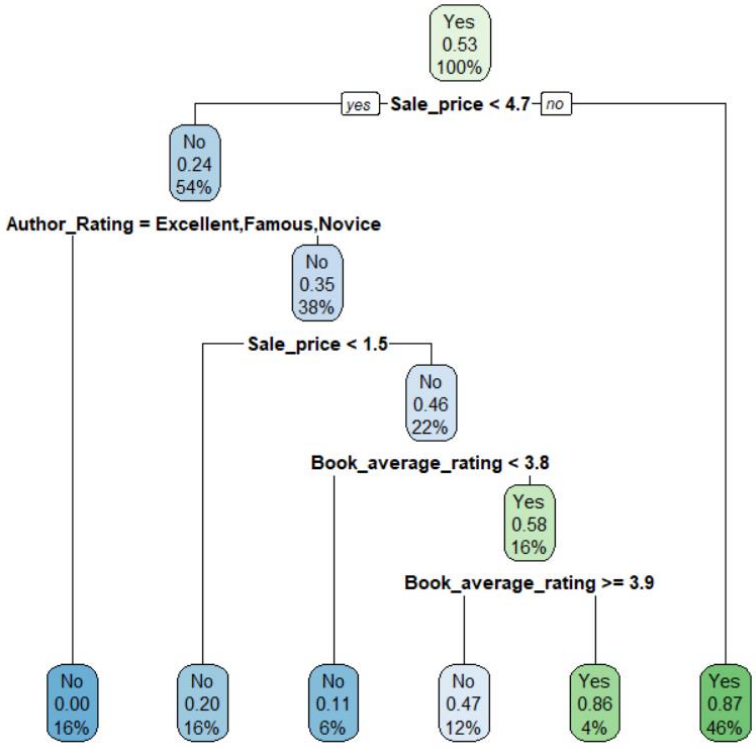

Figura 23. Arbore de clasificare

Așadar, prețul cărții (Sale_price) este cel mai important factor, pentru că e folosit în primul split. Dacă prețul este mai mare sau egal decât 4.7, cartea este aproape sigur un Yes (de succes). Pentru cărțile mai ieftine, contează ratingul autorului și ratingul cărții, adică autorii care fac parte din categoriile Excellent, Famous, Novice și cu prețuri mici tind să aibă No (adică nu au succes), iar autorii Intermediate pot avea succes dacă prețul e mediu și ratingul cărții e ridicat. Book_average_rating influențează doar în cazul în care prețul e mediu (1.5 - 4.7) și autorul e Intermediate.

```
> confuzie<-table(settestare1$High_Revenue, predictie)
> confuzie
     predictie
      No Yes
  No  56  29
  Yes 14  60
> #Eroarea de clasificare:
> mean(predictie!=settestare1$High_Revenue)
[1] 0.2704403
```

Figura 24. Matricea de confuzie pentru predicții de tip "class"

- Total observații: 56 + 29 + 14 + 60 = 159
- Clasificări corecte: 56 (No corect) + 60 (Yes corect) = 116 corecte
- Clasificări greșite: 29 (a prezis Yes dar era No) + 14 (a prezis No dar era Yes) = 43 greșite

Deci, eroarea de clasificare este de 27.04%, deci modelul funcționează decent, cu o acurateță de aproximativ 73%.

```
           No       Yes
1   0.8000000 0.2000000
2   0.8888889 0.1111111
3   0.8000000 0.2000000
4   1.0000000 0.0000000
5   0.8000000 0.2000000
6   0.1428571 0.8571429
7   0.5263158 0.4736842
8   0.8000000 0.2000000
9   0.8000000 0.2000000
10  0.5263158 0.4736842
```

Figura 25. Predicții de tip "prob"

Cartea 1 aparține clasei No cu probabilitatea de 0.8 și clasei Yes cu probabilitatea 0.2, etc. Pentru cartea 4 predicția este bună, deoarece este în clasa No cu probabilitatea 1.

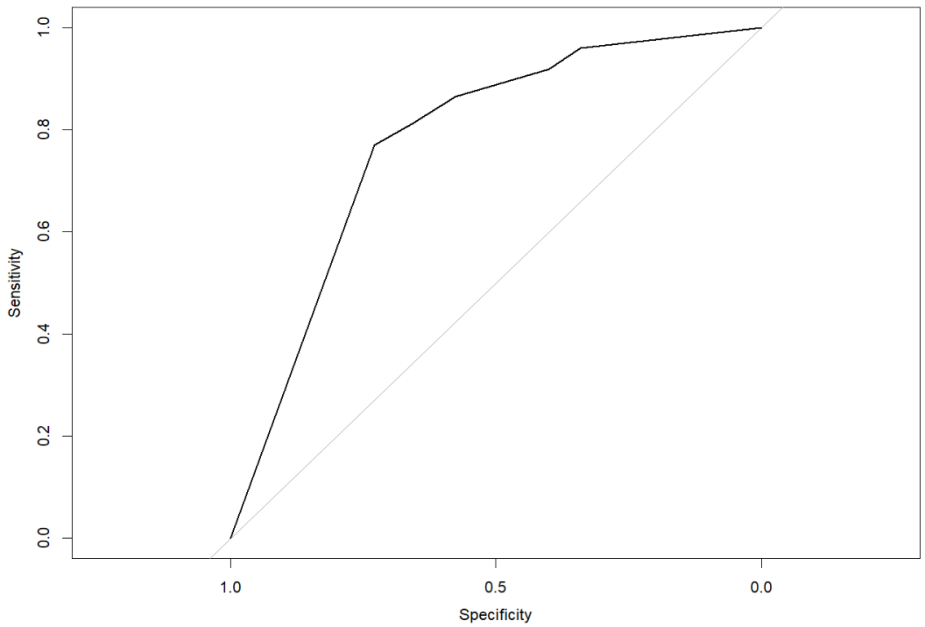

Figura 26. Grafic curba ROC

Curba neagră este clar deasupra diagonalei, ceea ce indică faptul că modelul are putere de discriminare bună între clasele Yes și No. Curba urcă rapid către colțul din stânga sus, care arată senzitivitate și specificitate ridicată la un anumit prag. Cu cât curba este mai apropiată de colțul stânga-sus (0,1), cu atât modelul este mai performant.

Valoarea curbei ROC este de 0.7759, deci clasificatorul poate distinge în proporție de 78% veniturile mari de cele mici.

În continuare, am folosit validarea încrucișată pentrua a determina parametrul optim de complexitate (CP) care corespunde erorii minime.

```
Classification tree:
rpart(formula = High_Revenue ~ Book_average_rating + Author_Rating +
    Sale_price, data = setantrenare1, method = "class")

Variables actually used in tree construction:
[1] Author_Rating       Book_average_rating Sale_price

Root node error: 74/158 = 0.46835

n= 158

        CP nsplit rel error  xerror     xstd
1 0.594595      0   1.00000 1.00000 0.084761
2 0.018018      1   0.40541 0.41892 0.067456
3 0.013514      4   0.35135 0.51351 0.072598
4 0.010000      5   0.33784 0.51351 0.072598
```

Figura 27. Output pentru CP

Valoarea optimă conform validării încrucișate este la xerror = 0.41892, cu CP = 0.018018 și 2 noduri terminale (nsplit = 1).

Mai jos, am realizat și graficul pentru parametrul de complexitate.

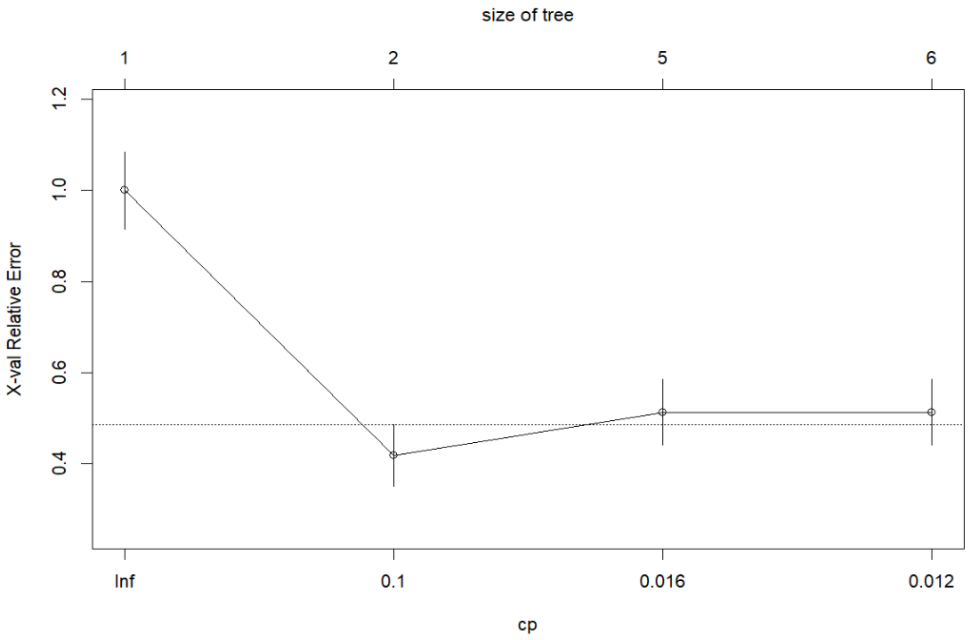

Figura 28. Grafic CP

Se observă că cel mai bun model este cel cu CP = 0.1 (size = 2), unde eroarea este minimă și stabilă.

După asta, am construit arborele curățat ținând cont de xerror.

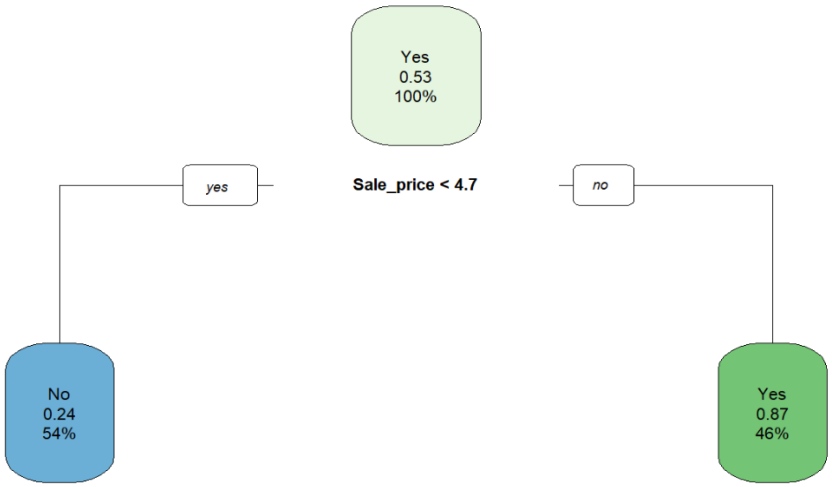

Figura 29. Arbore curățat

```
Classification tree:
rpart(formula = High_Revenue ~ Book_average_rating + Author_Rating +
    Sale_price, data = setantrenare1, method = "class")

Variables actually used in tree construction:
[1] Sale_price

Root node error: 74/158 = 0.46835

n= 158

        CP nsplit rel error  xerror     xstd
1 0.594595      0   1.00000 1.00000 0.084761
2 0.018018      1   0.40541 0.41892 0.067456
```

Figura 30. Output CP arbore curățat

Se confirmă astfel, că CP minim este 0.018018 și arborele are două noduri terminale.

```
  1   2   3   4   5   6   7   8   9  10  11  12  13  14  15  16  17  18  19  20  21  22  23  24  25  26  27  28
 No  No  No  No  No  No  No  No  No  No  No  No Yes  No  No  No Yes  No  No Yes  No  No  No  No Yes Yes Yes  No
 29  30  31  32  33  34  35  36  37  38  39  40  41  42  43  44  45  46  47  48  49  50  51  52  53  54  55  56
Yes  No  No  No Yes  No  No  No  No Yes  No Yes Yes Yes Yes  No  No Yes  No  No  No Yes  No  No  No  No Yes Yes
 57  58  59  60  61  62  63  64  65  66  67  68  69  70  71  72  73  74  75  76  77  78  79  80  81  82  83  84
Yes  No Yes Yes Yes Yes Yes  No  No Yes Yes Yes Yes  No  No Yes Yes  No Yes Yes Yes Yes Yes  No  No  No Yes  No
 85  86  87  88  89  90  91  92  93  94  95  96  97  98  99 100 101 102 103 104 105 106 107 108 109 110 111 112
Yes  No Yes  No  No Yes Yes  No Yes  No Yes  No Yes Yes  No Yes Yes  No Yes Yes Yes  No  No Yes  No  No  No  No
113 114 115 116 117 118 119 120 121 122 123 124 125 126 127 128 129 130 131 132 133 134 135 136 137 138 139 140
 No Yes Yes Yes Yes Yes Yes Yes  No  No Yes Yes  No Yes  No Yes Yes Yes Yes Yes  No Yes Yes Yes Yes Yes Yes  No
141 142 143 144 145 146 147 148 149 150 151 152 153 154 155 156 157 158 159
 No Yes Yes  No  No Yes Yes  No Yes  No Yes  No Yes  No Yes  No  No Yes Yes
Levels: No Yes
```

Figura 31. Predicții de tip "class" pentru arborele curățat

```
> confuzie1<-table(settestare1$High_Revenue, predictie2)
> confuzie1
     predictie2
      No Yes
  No  62  23
  Yes 17  57
> #Eroarea de clasificare
> mean(predictie2!=settestare1$High_Revenue)
[1] 0.2515723
```

Figura 32. Matricea de confuzie pentru predicții de tip "class"

Se observă că, după curățarea arborelui, eroarea de clasificare este mai mică, acuratețea modelului fiind de aproximativ 75%.

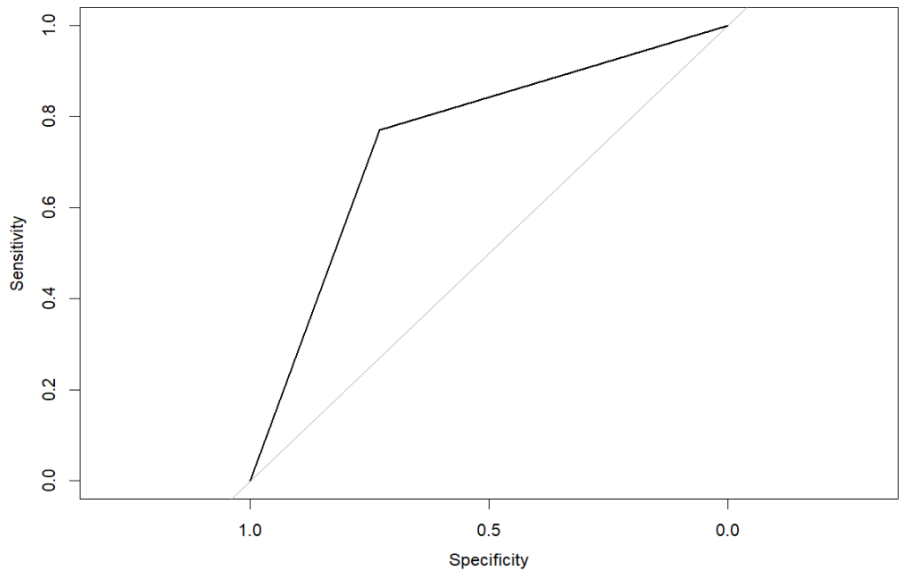

Figura 33. Grafic curba ROC (predicții de tip "prob")

Curba urcă brusc la aproximativ 0.75 pe axa Y, deci modelul reușește să identifice 75% dintre cazurile pozitive la un anumit prag. Specificitatea nu este constant ridicată, dar totuși este acceptabilă. Valoarea de sub curba ROC este 0.7498 și este mai mică decât cea determinată pentru arborele care nu a fost curățat înainte.

Deși AUC a scăzut, pentru că arborele a fost simplificat, modelul este mai robust și mai stabil la date noi.

Arbori de regresie

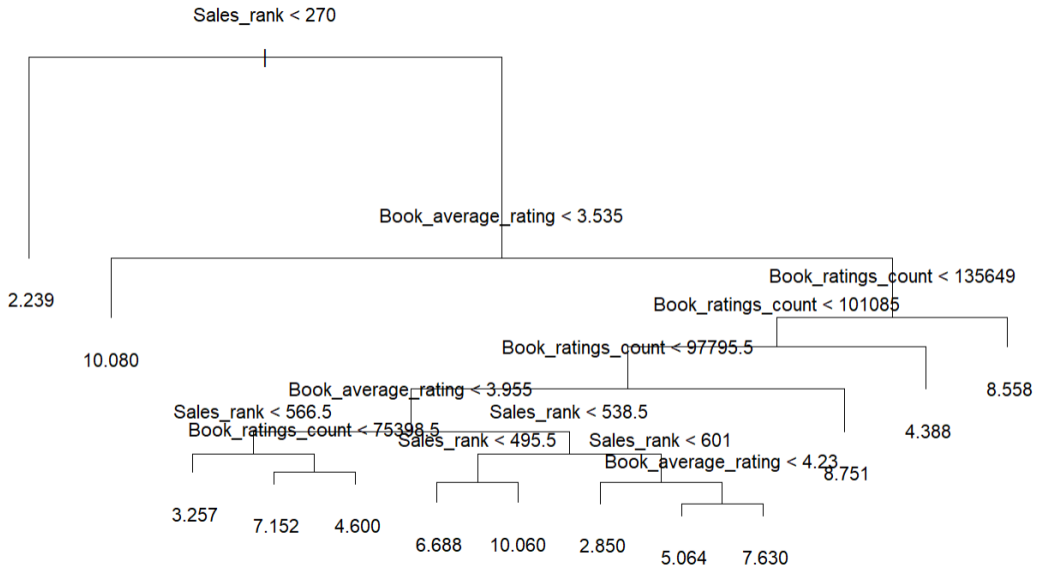

Figura 34. Arbore de regresie

Arborele conține prețul logaritmat pentru fiecare carte din nodul respectiv.

```
> cv.trees$size
 [1] 13 12 11 10  9  8  6  3  2  1
> cv.trees$dev
 [1] 2131.565 1996.295 1996.295 1827.569 1811.671 1753.300 1644.283 1657.091 1670.966 2044.903
```

Figura 35. Aplicarea funcției "cv.tree"

Cea mai mică eroare este 1644.283, la 6 noduri terminale, aici oprindu-se curățarea.

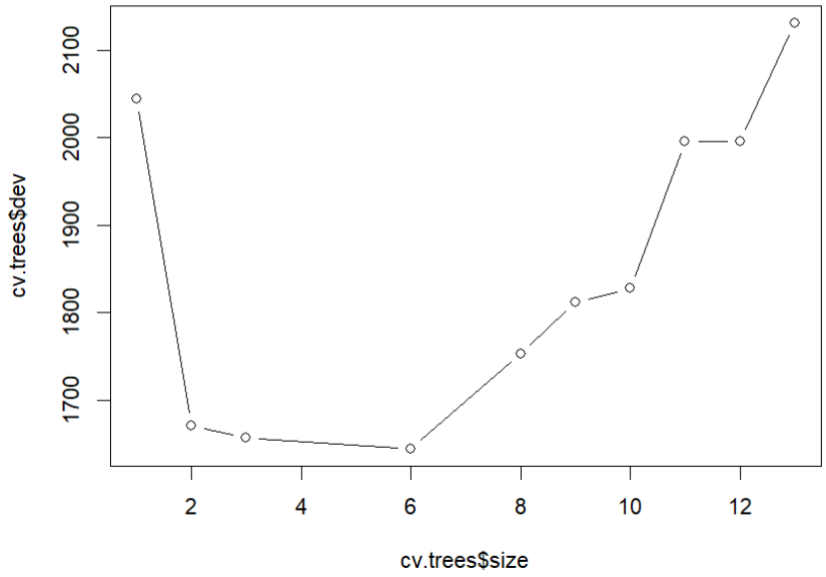

Figura 36. Grafic eroare

Din grafic se deduce că minimul erorii se distinge pentru o mărime a arborelui egală cu 6 noduri terminale.

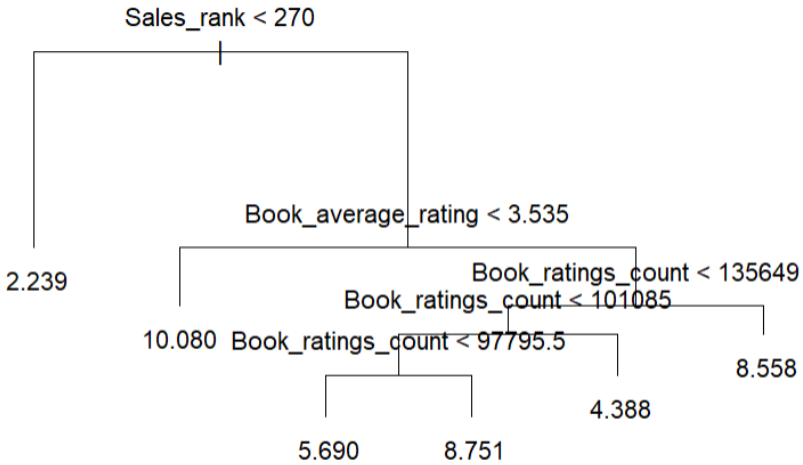

Figura 37. Arbore curățat

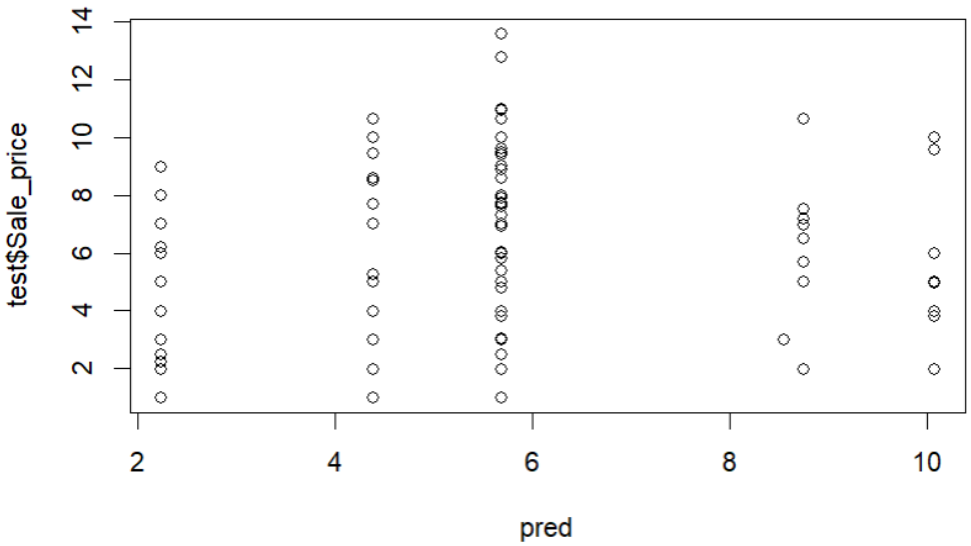

Figura 38. Grafic între valorile prezise model și valorile reale ale prețurilor

Valorile de pe axa X (pred) sunt discrete, în jurul valorilor 2, 4, 6, 8 și 10. Acest lucru sugerează că modelul produce predicții constante pentru grupuri de observații, fiind o caracteristică tipică pentru un arbore decizional, unde fiecare frunză dă o valoare fixă.

Punctele sunt răspândite vertical, fără un tipar evident, astfel că predicțiile nu sunt foarte precise, având o variație destul de mare față de valorile reale.

MSE măsoară media pătratelor diferențelor dintre valorile reale și valorile prezise. Cu cât MSE este mai mic, cu atât predicțiile modelului sunt mai apropiate de valorile reale. În acest caz, eroarea pătratică medie are valoarea de 11.32403, iar RMSE (3.36512) evidențiează că, în medie, modelul greșește cu aproximativ 3.36 unități față de valorile reale.

5. Utilizarea algoritmului KNN pentru clasificare

```
k-Nearest Neighbors

222 samples
  3 predictor
  2 classes: 'X0', 'X1'

Pre-processing: centered (3), scaled (3)
Resampling: Cross-Validated (10 fold, repeated 3 times)
Summary of sample sizes: 200, 200, 200, 199, 200, 200, ...
Resampling results across tuning parameters:

  k   ROC        Sens       Spec
   5  0.9327181  0.8648485  0.8787879
   7  0.9344089  0.8406061  0.8770202
   9  0.9357599  0.8287879  0.8944444
  11  0.9377422  0.8196970  0.8888889
  13  0.9381485  0.8166667  0.9151515
  15  0.9380544  0.8075758  0.8994949
  17  0.9372452  0.8106061  0.9058081
  19  0.9382691  0.8133333  0.9116162
  21  0.9398393  0.8290909  0.9063131
  23  0.9402606  0.8260606  0.9030303

ROC was used to select the optimal model using the largest value.
The final value used for the model was k = 23.
```

Figura 39. Output algoritm KNN

Cea mai mare valoarea a ariei de sub curba ROC este de 0.9402606 corespunzătoarea celor mai apropiați 23 vecini. Această valoare este foarte apropiată de 1, așadar modelul este considerat foarte bun și adecvat pentru separarea veniturilor mari de veniturile mici încasate de edituri.

Deși k = 23 are ROC-ul cel mai mare, senzitivitatea este ceva mai mică (0.826), ceea ce înseamnă că modelul poate rata unele venituri care sunt în clasa pozitivă. În schimb, specificitatea este bună (0.903), deci clasifică corect cazurile negative.

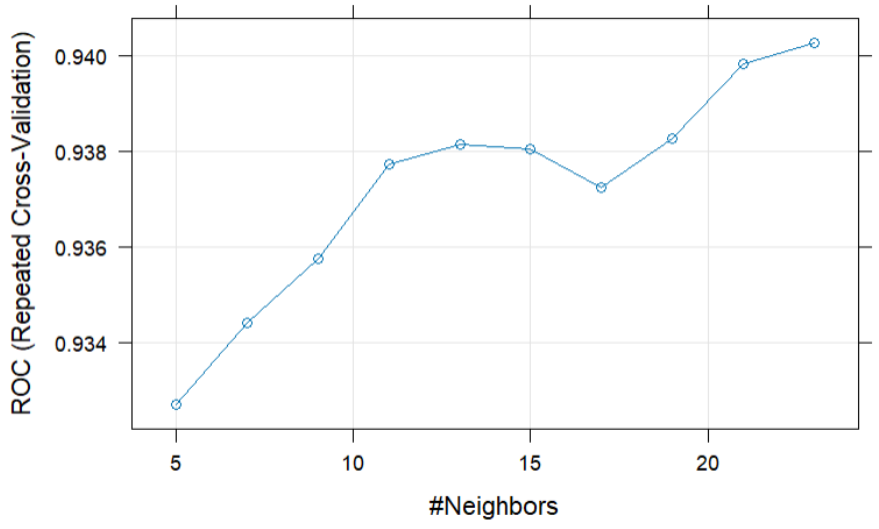

Figura 40. Grafic algoritm KNN (aria de sub curba ROC)

```
          X0        X1
1 0.6956522 0.3043478
2 0.5217391 0.4782609
3 0.5652174 0.4347826
4 0.2608696 0.7391304
5 0.3478261 0.6521739
6 0.4782609 0.5217391
```

Figura 41. Predicții de tip "prob"

Probabilitatea ca de pe urma primei cărți editura să încaseze un venit mare este de 0.3, iar pentru venit mic este 0.7, și așa mai departe.

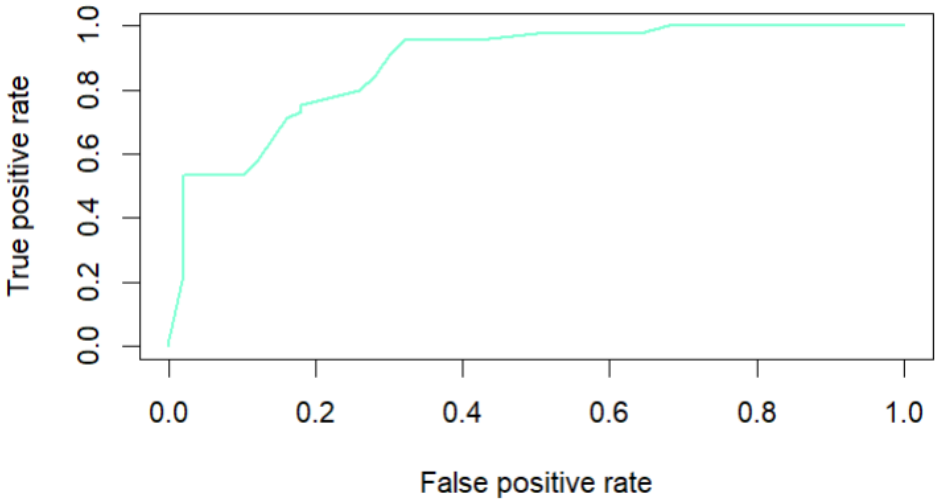

Figura 42. Grafic curba ROC

Aria de sub curba ROC indică șanse de 88.07% (valoarea lui auc) de separare a clasei pozitive (venit mare) de clasa negativă (venit mic).

6. Folosirea rețelelor neuronale pentru clasificare

Am ales să antrenez o rețea neuronală care clasifică un autor în una dintre cele patru categorii: Novice, Intermediate, Famous și Excellent. Pentru asta am folosit variabila Author_Rating din setul de date.

După aceea, am extras 70% din date pentru setul de antrenare și am adăgat în acest set încă 4 coloane pentru fiecare categorie de autor. De exemplu, coloana Novice conține TRUE dacă autorul e în categoria Novice și FALSE, în caz contrar.

Rețeaua realizată conține 4 noduri de ieșire, câte unul pentru fiecare categorie, 4 noduri de intrare (Book_average_rating, Book_ratings_count, Sale_price, Units_sold) și un strat ascuns cu 3 noduri.

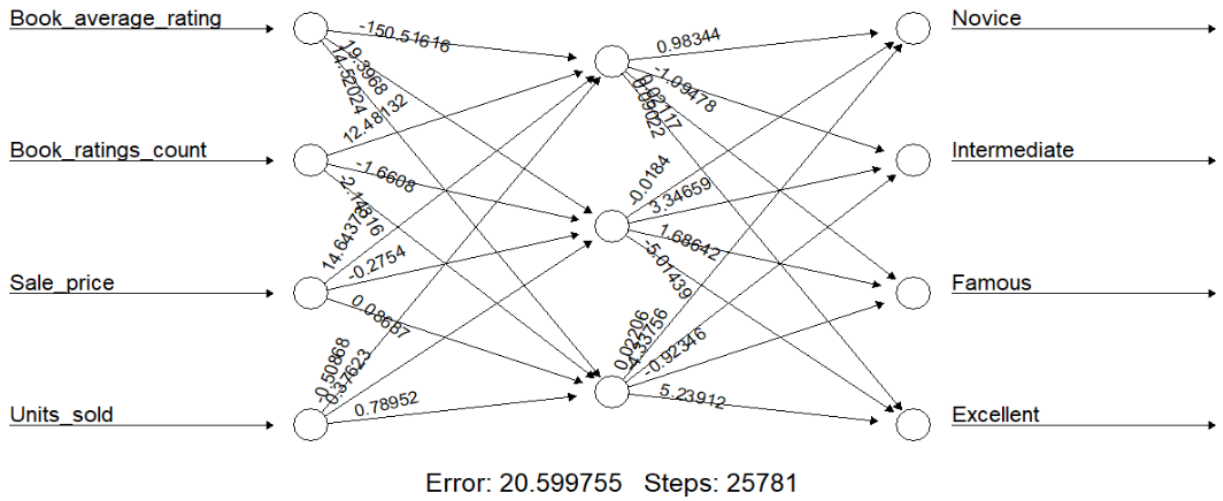

Figura 43. Grafic rețea neuronală

Din graficul de mai sus, se observă că eroarea minimă este aproximativ 20.6 și s-a obținut la pasul 25781. Numerele de pe săgeți reprezintă ponderile (greutățile). Dacă numărul este mare și pozitiv, acel semnal este amplificat, iar dacă este negativ, influența este inhibată. De exemplu, valoarea 19.3968 între Book_average_rating și al doilea neuron din stratul ascuns arată o influență foarte puternică, pe când între Book_average_rating și primul neuron influența este foarte slabă.

```
              [,1]       [,2]         [,3]          [,4]
 [1,] -0.001983305 0.75052555  0.016664622  0.2347791509
 [2,] -0.002198359 0.80163541 -0.003989108  0.2045252225
 [3,]  0.035916496 1.02930737  0.017965293 -0.0832363011
 [4,] -0.003399754 1.04771398  0.013308987 -0.0576712925
 [5,] -0.003481054 1.06405042  0.015544033 -0.0761625065
 [6,] -0.002291129 0.75490752  0.218441769  0.0289976709
 [7,] -0.003107271 0.98863233  0.006316273  0.0081147019
 [8,]  0.951326748 0.01244088  0.038108476 -0.0018668818
 [9,] -0.003151370 0.99795763  0.005967146 -0.0008185277
[10,] -0.003229680 1.01358182  0.008493514 -0.0188916281
```

Figura 44. Predicții pe setul de date

```
   Author_Rating    predictie
1   Intermediate Intermediate
2   Intermediate Intermediate
3   Intermediate Intermediate
4   Intermediate Intermediate
5   Intermediate Intermediate
6   Intermediate Intermediate
7   Intermediate Intermediate
8         Novice       Novice
9   Intermediate Intermediate
10  Intermediate Intermediate
```

Figura 45. Comparație între categoriile reale și cele prezise de model

	Excellent	Famous	Intermediate	Novice
Excellent	72	2	18	0
Famous	0	20	0	1
Intermediate	8	3	176	0
Novice	0	0	0	17

Figura 46. Maricea de confuzie

Acuratețea: (72+20+176+17) / (72+20+176+17+2+18+1+8+3) = 0.8997, adică 89.97%, deci este foarte bună.

Cele mai multe greșeli apar între clasele Excellent și Intermediate, probabil aceste clase sunt similare în caracteristici (ex: ratinguri mari, vânzări bune). Clasa Novice este perfect clasificată.

ANEXĂ – COD

```
#Importarea setului de date
library(readxl)
Date_proiect <- read_excel("Date_proiect.xlsx")
View(Date_proiect)

#Se ignora datele lipsa
Date_proiect <- na.omit(Date_proiect)
date <- Date_proiect

#Eliminarea coloanele care nu au valori numerice
date1 <- date[, -c(1,2,3,6,10)]

##Statistici descriptive
library(psych)
describe(date1)

#Boxplot
windows()
par(mfrow = c(1, 3))
boxplot(date$Book_average_rating, col = "maroon")
boxplot(date$Book_ratings_count, col = "maroon")
boxplot(date$Publisher_revenue, col = "maroon")
par(mfrow = c(1, 3))
boxplot(date$Sale_price, col = "maroon")
boxplot(date$Sales_rank, col = "maroon")
boxplot(date$Units_sold, col = "maroon")
```

```
#Identificare outlierii
outlieri_Publisher_revenue <- boxplot.stats(date$Publisher_revenue)$out
outlieri_Units_sold <- boxplot.stats(date$Units_sold)$out

#Eliminare outlierii
date2 <- date[!date$Publisher_revenue %in% outlieri_Publisher_revenue, ]
date2 <- date2[!date2$Units_sold %in% outlieri_Units_sold, ]

#Pt arbore
date_arbore <- date2

##Clusterizare fuzzy
library(e1071)

#Clusterizare cu 5 clustere, 100 iteratii si m=2
date3 <- date2[c(4,5,9)]

set.seed(123)
result<-cmeans(date3,3,100,m=2, method="cmeans")
result

#Graficul siluetei - pentru a evalua calitatea clusterizarii
library(cluster)
sil <- silhouette(apply(result$membership, 1, which.max), dist(date3))
plot(sil)

#Reprezentarea observatiilor intr-un sistem de axe cu valorile Gross_sales pe Ox si valorile
Sale_price pe Oy
```

```
plot(date3$Book_average_rating, date3$Sales_rank, col=result$cluster)
points(result$centers[,c(1,3)],col=1:5,pch=8,cex=2)

#Afisarea cartilor cu clusterele de care apartin
View(data.frame(Book = date2$Book_Name, Cluster = result$cluster))

#Grafic clustere
library(factoextra)
fviz_cluster(list(data=date3, cluster=result$cluster))

##Regresie logistica binomiala
#Crearea variabilei binare: 1 dacă Units_sold > mediana, altfel 0
library(dplyr)
median_units <- median(date2$Units_sold, na.rm = TRUE)
date2$High_Sales <- ifelse(date2$Units_sold > median_units, 1, 0)

#Transformarea in variabila de tip factor (pentru clasificare binara)
date2$High_Sales.f <- factor(date2$High_Sales)

#Impartirea datelor in set de antrenare (75%) si testare (25%)
library(caTools)
set.seed(88)

split<-sample.split(date2$High_Sales.f,SplitRatio = 0.75)

#Setul de antrenare
setantrenare<-subset(date2, split==TRUE)
```

```
#Setul de testare
settestare <-subset(date2, split==FALSE)

#Grafic
library(ggplot2)
plot <- ggplot(data = date2, aes(x = Book_ratings_count, y = Sale_price, color = High_Sales.f))
+
  geom_point(size = 3, alpha = 0.7) +
  scale_color_manual(values = c("coral1", "darkorchid1"), name = "High Sales") +
  labs(x = "Book Ratings Count", y = "Sale Price") +
  theme_minimal()
plot

#Model
model<-glm(High_Sales.f~Book_ratings_count+Sale_price, data=setantrenare, family =
binomial)
summary(model)

#Impactul variabilelor analizate asupra sanselor ca vanzarea sa fie mare
exp(coef(model))

#Utilizand functia contrasts() se vor factoriza categoriile
contrasts(date2$High_Sales.f)
#Astfel a fost atribuita valoarea 0 vanzarilor mici si 1 pentru vanzarile mari

#Predictii
prob<-predict(model, settestare, type='response')
prob
```

```
pred<-rep("0",dim(setantrenare)[1])
pred[prob>.5] ="1"

#Matricea de confuzie pentru setul de antrenare
table(pred, setantrenare$High_Sales.f)

#Introducem doua carti
predictie <- predict(model, newdata = data.frame(Book_ratings_count = c(10000, 50000),
Sale_price = c(10, 15)), type = "response")
predictie

#Evaluam daca cele doua carti au vanzare mare sau nu
predictie[1]<=0.5 #Prima carte are vanzare mica
predictie[2]<=0.5 #A doua carte are vanzare mica

#Predictia pe setul de testare
pred1<-rep("0", dim(settestare)[1])
pred1[prob>.5]="1"

#Matricea de confuzie pentru setul de testare
table(pred1, settestare$High_Sales.f)

#Acuratetea
mean(pred1==settestare$High_Sales.f)

#Curba ROC
library(ROCR)
p<-predict(model, newdata=settestare, type="response")
pr<-prediction(p, settestare$High_Sales.f)
```

```
prf<-performance(pr, measure="tpr", x.measure = "fpr")
plot(prf)

auc<-performance(pr, measure="auc")
auc<-auc@y.values[[1]]
auc

##Regresie multinomiala
#Transformarea variabilei raspuns "Author_Rating" in variabila factor, numita "Author_RatingF"
date2$Author_RatingF<-factor(date2$Author_Rating)

#Variabila "Author_Rating" ia patru valori posibile: "Novice", "Intermediate", "Famous", "Excellent";
#Se stabileste un nivel de referinta cu valoarea "Excellent"
date2$out<-relevel(date2$Author_RatingF, ref='Excellent')

library(nnet)
model2<-multinom(out~Units_sold+Sales_rank+Sale_price, data=date2, trace=FALSE)
summary(model2)

#Impactul variabilelor analizate
exp(coef(model2))

#Determinarea probabilitatilor folosind predict
predict(model2, date2)

predict(model2, date2, type="prob")
```

```
#Previzionarea valorile pentru cartile 3, 100, 150:
predict(model2, date2[c(3,100,150),], type="prob")

#Compararea predictiile modelului cu datele reale
matriceconfuzie<-table(date2$Author_Rating, predict(model2))
matriceconfuzie

#Acuratetea
mean(date2$Author_Rating == predict(model2))

##Arbori de decizie
#1.Arbore de clasificare
library(ISLR)
library(tree)
library(pROC)
library(rpart)

#Histograma
hist(date_arbore$Publisher_revenue, col="pink2")

#Crearea variabilei binare: "Yes" dacă Publisher_revenue > mediana, "No" in caz contrar
median_publisher <- median(date_arbore$Publisher_revenue, na.rm = TRUE)
date_arbore$High_Revenue <- ifelse(date_arbore$Publisher_revenue > median_publisher,
"Yes", "No")

#Eliminarea coloanei Publisher_revenue din setul de date
date_arbore$Publisher_revenue<-NULL
```

```
#Setul de antrenare si testare
set.seed(123)
antrenare1 <- sample(1:nrow(date_arbore), nrow(date_arbore)/2)
setantrenare1 <- date_arbore[antrenare1, ]
settestare1 <- date_arbore[-antrenare1, ]

#Definirea arborelui folosind testul de antrenare
arbore <- rpart(High_Revenue ~ Book_average_rating + Author_Rating + Sale_price, data =
setantrenare1, method = 'class')
plot(arbore)
text(arbore, pretty=0)
arbore

#Grafic mai sugestiv
library(rpart.plot)
windows()
rpart.plot(arbore, extra=106)

#Matricea de confuzie
table(setantrenare1$High_Revenue)

#Realizam predictia observatiilor din setul de testare
predictie<-predict(arbore, settestare1, type="class")
confuzie<-table(settestare1$High_Revenue, predictie)
confuzie

#Eroarea de clasificare
mean(predictie!=settestare1$High_Revenue)
```

```
#Alta predictie
predictie1 <-predict(arbore, settestare1, type="prob")
predictie1

#Curba ROC
curbaroc<-roc(settestare1$High_Revenue, predictie1[,"Yes"])
plot(curbaroc)
auc(curbaroc)
plotcp(arbore)

#Parametru de complexitate optim
mincp<-arbore$cptable[which.min(arbore$cptable[,"xerror"]), "CP"]
mincp
plotcp(arbore)

#Mai multe praguri pt CP
printcp(arbore)

#Arborele curatat
arbore1<-prune(arbore, cp=arbore$cptable[which.min(arbore$cptable[,'xerror']),"CP"])
rpart.plot(arbore1, extra=106)

printcp(arbore1)

#Predictie de tip class pe arborele curatat
predictie2<-predict(arbore1, settestare1, type="class")
predictie2
```

```
#Matricea de confuzie
confuzie1<-table(settestare1$High_Revenue, predictie2)
confuzie1

#Eroarea de clasificare
mean(predictie2!=settestare1$High_Revenue)

#Predictie de tip prob pe arborele curatat
predictie3<-predict(arbore1, settestare1, type="prob")
predictie3

#Curba roc
curbaroc1<-roc(settestare1$High_Revenue, predictie3[,"Yes"])
plot(curbaroc1)
auc(curbaroc1)

#2. Arbore de regresie
library(caret)
set.seed(102)
split <- createDataPartition(y=date2$Sale_price, p=0.5, list=FALSE)

#Definim seturile de antrenare si testare
train <- date2[split, ]
test <- date2[-split, ]

#Definim arborele
arbore_regresie <- tree(Sale_price ~ Book_average_rating + Sales_rank + Book_ratings_count,
train)
plot(arbore_regresie)
```

```
text(arbore_regresie, pretty = 0)

#Pentru curatarea arborelui
cv.trees <- cv.tree(arbore_regresie)
cv.trees$size
cv.trees$dev

#Grafic eroare
plot(cv.trees$size, cv.trees$dev, type='b')

#Se construieste arborele curatat
arbore_regresie1 <- prune.tree(arbore_regresie, best=6)
#best este un parametru ce primeste ca si valoare nr optim de noduri terminale

plot(arbore_regresie1)
text(arbore_regresie1, pretty=0)

#Facem predictii pe setul de testare
pred <- predict(arbore_regresie1, test)
pred

#Reprezentam grafic pretul logaritmat al fiecarei carti
plot(pred, test$Sale_price)

#Eroarea de predictie (MSE)
mean((pred-test$Sale_price)^2)
```

```
#RMSE
sqrt(mean((pred-test$Sale_price)^2))

##KNN (K-Nearest Neighbors - Metoda celor mai apropiati k vecini)
library(caret)
library(e1071)

#Variabila High_Revenue
median_publisher <- median(date2$Publisher_revenue, na.rm = TRUE)
date2$High_Revenue <- ifelse(date2$Publisher_revenue > median_publisher, 1, 0)

#Vom transforma variabila dependenta win.loss in variabila de tip factor
date2$HighRevenue <- as.factor(date2$High_Revenue)

set.seed(101)

#Vom imparti setul de date in antrenare si testare cu 70% antrenare
index <- sample(2, nrow(date2), replace=TRUE, prob=c(0.7, 0.3))
index

#Definim seturile de antrenare si testare
set_antrenare <- date2[index==1, ]
set_testare <- date2[index==2, ]

#Niveluri
levels(set_antrenare$HighRevenue) <- make.names(levels(factor(set_antrenare$HighRevenue)))
levels(set_testare$HighRevenue) <- make.names(levels(factor(set_testare$HighRevenue)))
```

```
#Cross-validation

repeats=3

numbers=10

set.seed(1234)

x=trainControl(method="repeatedcv", number=numbers, repeats=repeats, classProbs = TRUE,
summaryFunction = twoClassSummary)


tunel=10


#Algoritmul

model_knn <- train(HighRevenue~Book_average_rating + Sale_price + Book_ratings_count,
data=set_antrenare, method="knn", preProcess=c("center", "scale"), trControl=x, metric="ROC",
tuneLength=tunel)

model_knn


#Grafic

plot(model_knn) #pe ox avem nr de vecini iar pe oy avem valorile pt curba ROC


#Predictia clasei pe setul de testare

valid_pred <- predict(model_knn, set_testare, type = "prob")

head(valid_pred)


#Grafic si aria de sub curba ROC pt setul de testare

library(ROCR)

pred_val <- prediction(valid_pred[,2], set_testare$HighRevenue)

perf_val <- performance(pred_val, "tpr","fpr")

plot(perf_val, col="aquamarine", lwd=1.5)

auc<-performance(pred_val,measure="auc")

auc<-auc@y.values[[1]]
```

```
auc

##Retele neuronale
#Eliminare coloane
date_retele <- date2[-c(1,2,6,10)]

maxim <- apply(date_retele[2:7], 2, max)
minim <- apply(date_retele[2:7], 2, min)

#Aplicam standardizarea max-min
date_std <- as.data.frame(scale(date_retele[2:7], center=minim, scale=maxim-minim))
View(date_std)

date_std1 <- data.frame(date_std, date_retele$Author_Rating)
colnames(date_std1)[which(colnames(date_std1) == "date_retele.Author_Rating")] <-
"Author_Rating"

set.seed(123)
index <- sample(2, nrow(date_std1), replace=TRUE, prob=c(0.7, 0.3))

#Seturile de antrenare si testare
antrenare <- date_std1[index==1, ]
testare <- date_std1[index==2, ]

#Transformarea cele patru clase din Author_Rating adaugand coloanele in antrenare
antrenare$Novice <- c(antrenare$Author_Rating == "Novice")
antrenare$Intermediate <- c(antrenare$Author_Rating == "Intermediate")
antrenare$Famous <- c(antrenare$Author_Rating == "Famous")
antrenare$Excellent <- c(antrenare$Author_Rating == "Excellent")
```

```
#Se elimina coloana Author_Rating
antrenare$Author_Rating <- NULL
head(antrenare)

#Antrenarea retelei neuronale ce va contine 5 noduri in primul strat ascuns si 3 in al doilea
library(neuralnet)

retea <-
neuralnet(Novice+Intermediate+Famous+Excellent~Book_average_rating+Book_ratings_count
+Sale_price+Units_sold,
                antrenare, hidden =3, lifesign = "full", stepmax = 1e6)

#Grafic retea neuronala
plot(retea, rep="best", intercept = FALSE)

#Predictii pentru cele 4 categorii
predictie <- compute(retea, date_std1[-c(3,5,7)])
predictie$net.result[1:10, ]

#Vom extrage categoriile din predictii astfel:
rezultat <- 0
for(i in 1:317) { rezultat[i] <- which.max(predictie$net.result[i,])}
for(i in 1:317) {
  if (rezultat[i]==1) { rezultat[i] <- "Novice" }
  else if (rezultat[i]==2) { rezultat[i] <- "Intermediate" }
  else if (rezultat[i]==3) { rezultat[i] <- "Famous" }
  else if (rezultat[i]==4) { rezultat[i] <- "Excellent" }
}
```

```
#Comparam datele
comparatie <- date_std1
comparatie$predictie <- rezultat
comparatie

#Setul de date comparatie contine in coloanele 7 si 8, adica valorile reale si cele previzionate
comparatie[1:10, c(7,8)]

#Matricea de confuzie
tab <- table(comparatie$Author_Rating, comparatie$predictie)
tab
```